《The road to AGI》

YKY 甄景贤

March 3, 2020

Table of contents

多谢 支持 ☺️

BERT 的革命性意义

- BERT 利用平常的文本 induce 出知识，而这 representation 具有 通用性 (universality) :

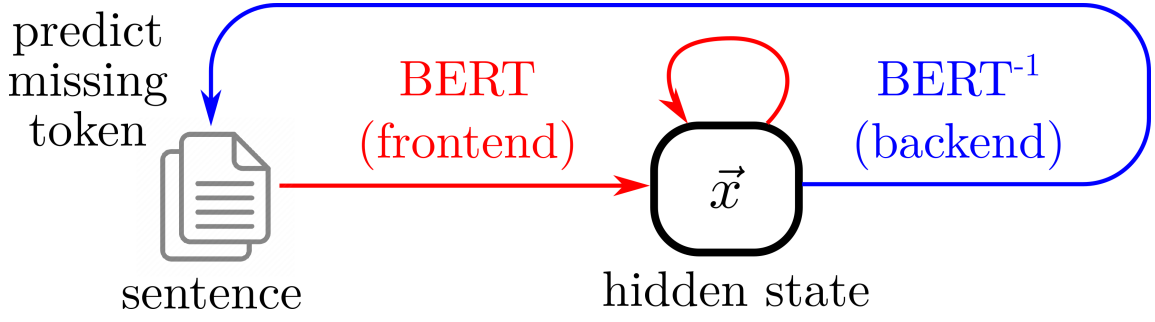

(1)

换句话说：隐状态的 representation 压缩了句子的意思，而它可以应用在别的场景下

- This implies that human-level AI can be *induced* from existing corpora, 而不需要重复像人类婴儿成长的学习阶段
- Such corpora can include items such as images, movies with dialogues / subtitles
- 这种训练方法是较早的另一篇论文提出，它并不属於 BERT 的内部结构

从 BERT 过渡到 AGI

- 词语 组成 句子，类比於 逻辑中，概念 组成 逻辑命题
- 抽象地说，逻辑语言 可以看成是一种有 2 个运算的 代数结构，可以看成是 加法 $\wedge$ 和 乘法 $\cdot$，其中 乘法 是不可交换的，但加法 可交换
- 例如 两个命题：

$$我 \cdot 爱 \cdot 妳 \ \wedge \ 妳 \cdot 爱 \cdot 我 \tag{2}$$

- 这种逻辑结构 可以用 两层 的 BERT 模型 处理：

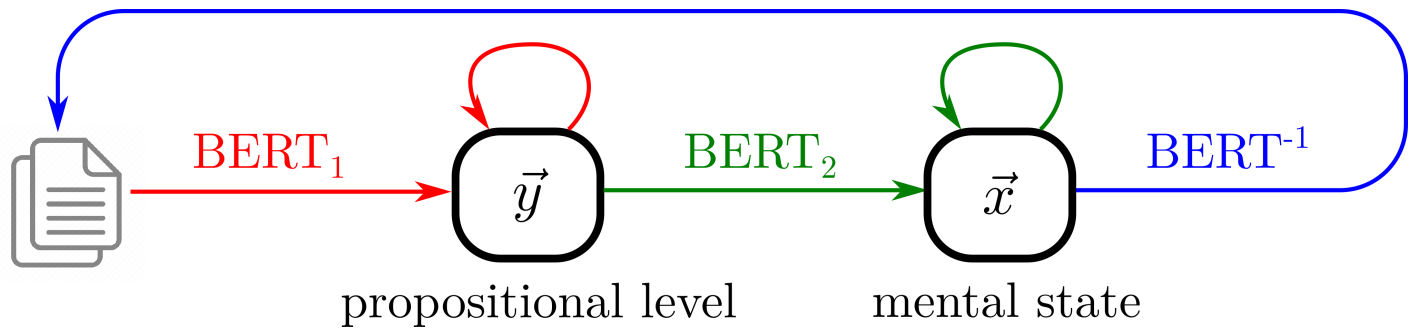

(3)

（第一层似乎可以纳入到第二层，简化整个模型）

- 我发现 最难处理的问题，是在第 2 层 的状态 $\vec{x}$. 它是一个 逻辑命题 的 集合，集合中元素有可交换性，亦即 permutation invariance. 这看似简单的特性，其实带来很大的麻烦

「集」结构 带来麻烦

- Word2Vec 也是革命性的；由 Word2Vec 演变成 Sentence2Vec 则比较容易，基本上只是 向量的 延长 (concatenation)；逻辑命题 类似於 sentence
- 假设 全体逻辑命题的空间是 $\mathbb{P}$，则 命题集合 的空间是 $2^{\mathbb{P}}$，非常庞大
- 如果限制 状态 $\vec{x}$ = working memory 只有 10 个命题，$\vec{x}$ 的空间是 $\mathbb{P}^{10}/\sim$ 其中 $\sim$ 是对称群 $\mathfrak{S}_{10}$ 的等价关系。换句话说 $2^{\mathbb{P}} \cong \coprod_{n=0}^{\infty} \mathbb{P}^n/\mathfrak{S}_n$
- $\mathbb{P}^n/\mathfrak{S}_n$ 虽然是 $\mathbb{P}^n$ 的商空间，但 $\mathfrak{S}_n$-不变性 很难用神经网络实现
- 现时 比较可行的办法，是将 状态 $\vec{x}$ 实现成 一个时间上的「轮盘」，每个 表示一个命题：

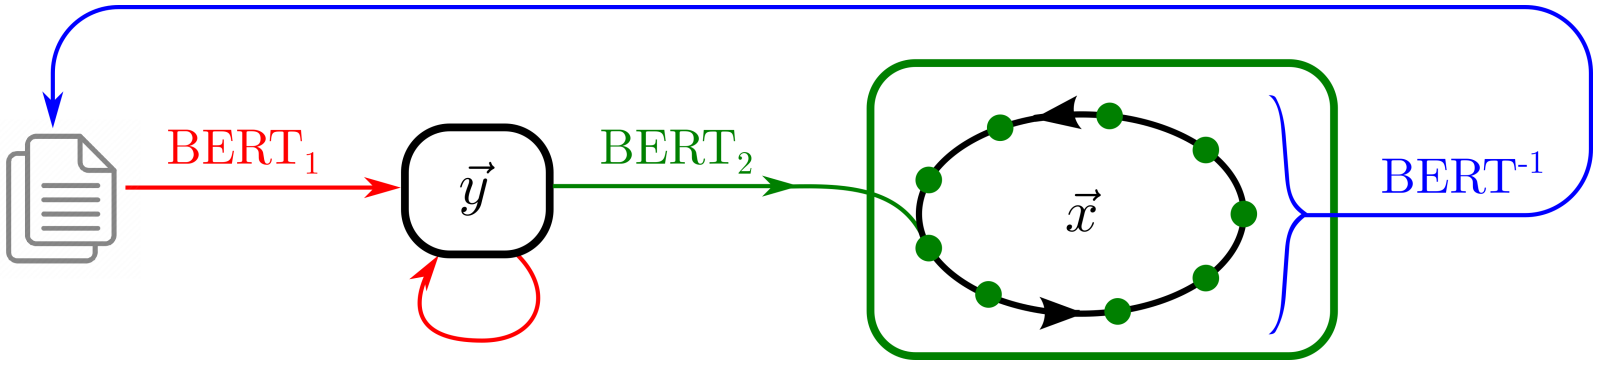

(4)

- 有趣的是，如果用「轮盘」方法，BERT 的 注意力机制 有特殊意义....

Attention 是什么？

- 注意力 最初起源於 Seq2seq，后来 BERT 引入 self-attention
- 在 Seq2seq 中，编码器 (encoder) 由下式给出，它将输入的词语 x_i 转化成一连串的 隐状态 h_i：

$$h_t = \text{RNN}_{encode}(x_t, h_{t-1}) \tag{5}$$

- 这些 h_i 可以综合成单一个 隐状态 $c = q(h_1, ..., h_n)$.
- 这个 c 被「寄予厚望」，它浓缩了整个句子的意义
- 解码器 的结构类似，它的隐状态是 s_t，输出 y_t：

$$s_t = \text{RNN}_{decode}(y_t, s_{t-1}, c_t) \tag{6}$$

- 注意最后的 c_t 依赖时间，它是隐状态 h_j 的 加权平均：

$$c_i = \sum_j \alpha_{ij} h_j \tag{7}$$

- 其中 α_{ij} 量度 输入 / 输出 的隐状态之间的 相似度，取其最大值：

$$\alpha_{ij} = \text{softmax}\{\langle s_i, h_j \rangle\} \tag{8}$$

换句话说，α_{ij} 选择 最接近 h_j 的 s_i

Attention 在逻辑中的用处

我这样理解 attention：

- 例如，翻译时，输入 / 输出句子中「动词」的位置可以是不同的
- 当 解码器需要一个「动词」时，它的隐状态 s_t 含有「动词」的意思
- Attention 机制 找出最接近「动词」的 编码器的隐状态（可以 ≥ 1 个）$\sum h_j$，交给 解码器，这是一种 information retrieval
- 例如，将 M 件东西 映射 到 N 件东西，可以有 N^M 个 mappings，这是非常庞大的空间。但如果这些物件有 类别，而同类只映射到同类，则可以用 attention 简化 mappings
- 所以 attention 是一种 inductive bias，它大大地缩小 mapping 空间
- 在逻辑的场景下，需要的 mapping 是 f : 命题集合 $\to$ 命题

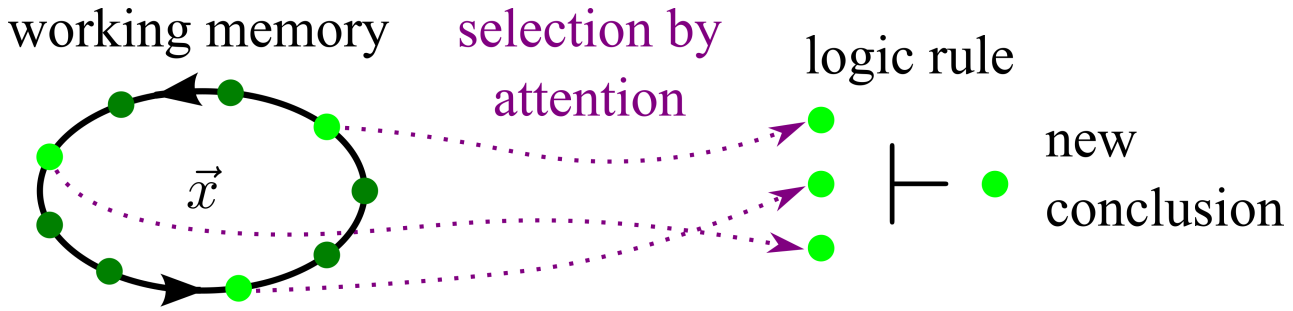

(9)

要设计一种新的 attention

- 逻辑 attention 和 传统 attention 要求略有不同，这是关键的一步
- 不是「同类映射到同类」，而是要在庞大的 logic rules 空间中找到适用 (applicable) 的 rules
- 隐状态 s_t 代表 “search state’’，注意力 的目的是 选择 s_t 所需要的那些命题，交给 解码器
- 注意：逻辑 attention 从 M 个命题中 选择 N 个命题，$M > N$. 这是 inductive bias. 而 Symmetric NN 的做法，只是要求 M 个命题 的 置换不变性，所以它浪费了资源在很多 “don’t care” 的命题上
- 换句话说，selection 所带来的 bias 如果足够强，似乎不需要 symmetric. 很巧合地，再次应验了 “attention is all you need” 这句话

多谢收看 ☺️